

PURWARUPA APLIKASI MACHINE LEARNING AUDIT INTERN PREDIKSI TENDER BERPOTENSI MASALAH

Eka C. Setyawan, ST, MAk, CFrA, CITA, CDSP, OFC

Abstraksi

This paper presents a prototype machine learning (ML) application designed to assist internal auditors in predicting potentially problematic tenders, thereby reducing the risks associated with tender audits. The application leverages the K-Nearest Neighbors (KNN) algorithm, a supervised learning method, to classify tenders based on historical audit findings and tender-related data. The results show that the KNN-based model can effectively predict tenders with potential findings, offering auditors a data-driven approach to prioritizing their audits with an accurate score of 73%. While the model is promising, its accuracy is dependent on the quality and quantity of input data. Future enhancements include expanding the dataset and incorporating additional variables such as objections, company supporting information, and complaints. This study highlights the potential of machine learning in improving the internal audit process, particularly in identifying high-risk tenders, and underscores the importance of robust data collection and preprocessing in developing effective ML solutions.

1. Latarbelakang

Sebagaimana amanah pasal 11 dalam Peraturan Pemerintah Republik Indonesia Nomor 60 Tahun 2008 tentang SPIP bahwa audit intern diharapkan mampu memberikan peringatan dini (*early warning system*) untuk mencegah penyimpangan dan meningkatkan tata kelola organisasi. Hal ini, mencakup berbagai aspek operasional, administratif, keuangan, dan kebijakan yang ada di dalam Kementerian/Lembaga/Badan, termasuk di dalamnya adalah penanganan permasalahan tender yang kerap menjadi salah satu pintu korupsi di negeri ini. Data Indonesia Corruption Watch (ICW) pada 2016 sampai 2020 menunjukkan sebanyak 49,1% atau 1.093 kasus dari 2.227 kasus yang ditangani penegak hukum, terkait dengan PBJ, kerugian negara yang ditimbulkan mencapai Rp 5,3 triliun. (sumber: <https://antikorupsi.org/id/tender-barang-dan-jasa-pemerintah-lahan-basah-korupsi>)

Dalam pelaksanaan audit tidak dipungkiri akan muncul risiko audit pemeriksaan tender, yaitu risiko yang terjadi pada saat Auditor melakukan pemeriksaan tender pada saat pelaksanaan audit, yaitu:

- 1) Adanya kemungkinan ketidakmampuan dalam mencegah atau mendeteksi suatu tender yang berpotensi terjadi permasalahan; atau
- 2) Telah terpakainya sumber daya auditor untuk melakukan pemeriksaan suatu tender yang diduga bermasalah ternyata tidak bermasalah (*false positive red flags*)

Kemunculan risiko pemeriksaan tender dimaksud termasuk dalam risiko uji petik audit, maka perlu dimitigasi karena dapat mempengaruhi pandangan publik terhadap mutu audit dan apabila tender yang terperiksa adalah objek audit dengan tujuan tertentu yang bersumber perintah Pimpinan Organisasi maka dapat disinyalir pertimbangan Pimpinan Organisasi belum didasarkan analisa yang mendalam, karena seharusnya setiap pemilihan objek audit harus tepat sasaran agar pelaksanaan audit terjamin efektifitas dan efisiensinya.

Penyebab risiko dimaksud dapat bervariasi tergantung pada konteks organisasi dan lingkup kasusnya. Namun, secara umum dan berdasarkan pengalaman, salah satu kronologi penyebab risiko dimaksud dapat terjadi sebagai berikut:

- 1) Adanya keterbatasan personil dan anggaran tim Auditor sehingga pemeriksaan tender di Unit Kerja diperiksa dilakukan secara sampling, namun pemilihan sampling dimaksud hanya berdasarkan:
 - a) Nilai tender
 - b) Jenis tender
 - c) Kompleksitas pekerjaan
 - d) Progres pekerjaan dimana seringkali memprioritaskan pekerjaan yang sudah selesai sebagai urutan pertama untuk dilakukan pemeriksaan
- 2) Keterbatasan waktu sehingga pengumpulan informasi atas pekerjaan yang menjadi target pemeriksaan Auditor tidak maksimal, mengutamakan informasi progress fisik dan keuangan pekerjaan tersebut.

2. Studi Pustaka

1) *Machine learning*

Machine learning adalah ilmu pengembangan algoritma dan model secara statistik melalui pemrograman komputer untuk menjalankan tugas tanpa instruksi eksplisit, mengandalkan pola serta inferensi sebagai gantinya. Pemrograman komputer tersebut menggunakan algoritma khusus untuk memproses data historis berjumlah besar dan mengidentifikasi pola datanya. Sehingga memungkinkan untuk memprediksi hasil yang lebih akurat dari set data input yang diberikan.

Gagasan utama di balik *machine learning* adalah hubungan matematis yang ada antara semua kombinasi data input dan output. Model *machine learning* tidak mengetahui hubungan ini sebelumnya, tetapi dapat menerka jika diberikan dataset yang cukup. Hal ini berarti setiap algoritma dalam *machine learning* dibangun dengan pendekatan matematika yang dapat dimodifikasi. Dengan kata lain, *machine learning* berfokus pada prinsip bahwa semua poin data kompleks dapat dihubungkan secara matematis oleh sistem komputer selama sistem komputer tersebut memiliki data dan daya komputasi yang cukup untuk memproses data tersebut. Oleh karena itu, keakuratan output tersebut secara langsung tergantung pada algoritma yang digunakan, kualitas dan kecukupan datasetnya.

Hal-hal yang perlu dipertimbangkan dalam implementasi *machine learning* adalah: 1)Kecukupan dan kualitas dataset sebagai bahan *machine learning*; 2)Spesifikasi perangkat keras yang memadai; 3)Pemahaman pemrograman komputer dan statistik yang cukup.

2) *Algoritma Machine Learning K-Nearest Neighbors (KNN)*

K-Nearest Neighbors (KNN) adalah algoritma supervised learning yang digunakan untuk klasifikasi dan regresi. Klasifikasi dengan KNN dilakukan dengan mencari (k) tetangga terdekat dari suatu data point berdasarkan jarak tertentu (misalnya, Euclidean distance) dan menentukan kelasnya berdasarkan mayoritas kelas dari tetangga tersebut. Kelebihan KNN antara lain mudah diimplementasikan dan tidak memerlukan proses pelatihan yang rumit. Beberapa penelitian telah menguji efektivitas algoritma KNN dalam mendeteksi *fraud*:

No	Peneliti	Deskripsi
1	Zhang et al. (2018)	menggunakan algoritma KNN untuk mendeteksi <i>fraud</i> pada transaksi kartu kredit. Mereka membandingkan kinerja KNN dengan beberapa algoritma lain seperti <i>Logistic Regression</i> , <i>Decision Tree</i> , dan <i>Random Forest</i> . Hasil penelitian menunjukkan bahwa KNN memberikan akurasi yang cukup baik, terutama ketika dataset memiliki fitur yang relevan dan terdistribusi secara merata. Namun, KNN cenderung kurang efektif ketika dataset sangat tidak seimbang, di mana jumlah transaksi <i>fraud</i> jauh lebih sedikit dibandingkan transaksi normal.
2	Kumar dan Vishwakarma (2019)	melakukan eksperimen dengan menggunakan KNN untuk mendeteksi <i>fraud</i> pada dataset keuangan. Mereka menemukan bahwa KNN dapat memberikan hasil yang baik ketika dilakukan preprocessing data, seperti normalisasi dan penanganan data yang tidak seimbang dengan teknik oversampling (misalnya, SMOTE). Selain itu, mereka juga mencatat bahwa pemilihan nilai (k) yang tepat sangat penting untuk meningkatkan kinerja KNN
3	Patel et al. (2020)	mengkombinasikan KNN dengan metode ensemble learning untuk meningkatkan kinerja deteksi <i>fraud</i> . Mereka menggunakan teknik seperti Bagging dan Boosting untuk menggabungkan beberapa model KNN. Hasilnya menunjukkan bahwa kombinasi ini dapat meningkatkan akurasi dan mengurangi false positive rate dibandingkan menggunakan KNN secara standalone
4	Al-Milli dan Al-Khatib (2021)	Mereka menemukan bahwa KNN efektif dalam mendeteksi <i>fraud</i> ketika dataset memiliki fitur yang relevan dan jumlah dimensi yang tidak terlalu tinggi. Namun, mereka juga mencatat bahwa KNN memerlukan waktu komputasi yang lebih lama dibandingkan algoritma lain seperti <i>Naive Bayes</i> atau <i>Support Vector Machine</i> (SVM)

Kelebihan algoritma KNN mudah diimplementasikan dan tidak memerlukan pelatihan yang rumit dan efektif untuk dataset dengan pola yang jelas dan fitur yang relevan. Sedangkan, kelemahan algoritma KNN memerlukan komputasi yang besar untuk dataset yang besar dan sensitif terhadap data yang tidak seimbang (*imbalanced data*).

3) Penelitian sebelumnya terkait deteksi kecurangan tender (Audit)

Mengacu pada penelitian sebelumnya oleh Venter (2007), dibandingkan dengan penelitian tentang fungsi bisnis lainnya, terdapat kekurangan penelitian tentang kecurangan tender dari perspektif manajemen risiko. Selain itu, implementasi *machine learning* belum diterapkan untuk mendeteksi dan memprediksi tender pada saat penelitian tersebut dilakukan.

Mengacu pada penelitian sebelumnya oleh Christensen et al. (2025) menunjukkan bahwa Generative AI (Artificial Intelligence) dapat meningkatkan efektivitas identifikasi risiko fraud oleh auditor. Namun, masih perlu eksplorasi lebih lanjut tentang bagaimana caranya agar dapat diterapkan dalam lingkungan audit yang kompleks dan beragam, termasuk aspek regulasi, kepatuhan, dan penerimaan auditor di lapangan

Kita ketahui Bersama, sampai dengan saat ini, sektor publik maupun privat beranggapan permasalahan tender adalah permasalahan yang sangat mengganggu kinerja, sehingga keduanya

berharap ditemukan cara efektif dan efisien untuk mendeteksi hal tersebut. Banyak penelitian sebelumnya tentang investigasi kecurangan tender menyatakan bahwa investigasi manual memiliki permintaan yang sangat tinggi akan pemeriksa yang terlatih dengan baik, yang mungkin cukup terbatas keberadaan sumber daya manusianya dan sangat sedikit bekerja di sektor publik (pemerintahan)

Oleh karena itu, peneliti berharap dengan rancangan purwarupa sederhana ini dapat menunjukkan implementasi *machine learning* untuk memprediksi tender yang berpotensi masalah dan adanya purwarupa ini bagi Auditor Intern dapat meningkatkan efektivitas dan efisiensi pemilihan tender sebagai objek audit.

3. Metodologi

a. Identifikasi tujuan

Pada karya tulis ini, tujuan utamanya adalah bagaimana merancang sebuah pemograman *machine learning* yang mampu memprediksi tender yang berpotensi terdapat temuan sehingga memitigasi risiko pemeriksaan tender yang dialami oleh Auditor, dengan kata lain pemilihan target pemeriksaan adalah tender yang diprediksi bermasalah.

b. Pengumpulan Data

Pengumpulan data sebagai dataset *machine learning*, didapatkan dari hasil pengolahan data meliputi:

- 1) Informasi hasil audit yang telah ditindaklanjuti tuntas oleh Auditor, dengan substansi temuan tender barang/jasa bermasalah, terdiri dari:
 - a) Kelebihan pembayaran pekerjaan pada pekerjaan konstruksi;
 - b) Realisasi volume pekerjaan tidak sesuai dengan yang dilaporkan;
 - c) Spesifikasi Teknis pekerjaan Pembangunan tidak sesuai dengan seharusnya;
 - d) Perusahaan pendukung di lapangan tidak sesuai dengan seharusnya di dokumen penawaran;
 - e) Penyelesaian pekerjaan dilapangan terlambat;
 - f) Pemanfaatan barang hasil tender barang/jasa yang tidak sesuai peruntukan atau mangkrak
- 2) Pelaksanaan kegiatan survei keberadaan Penyedia barang/jasa yang tercantum namanya di dalam data umum laporan hasil audit termasuk penyedia yang bermasalah dalam pelaksanaan tender barang/jasa
- 3) Informasi umum tender dari SPSE (lpse.depkeu.go.id)
- 4) Informasi skor nilai PFA dari situs opentender ICW (www.opentender.net)

c. Persiapan data


Selama kurun waktu 1 bulan, data yang dapat dikumpulkan oleh Peneliti sebanyak 217, kemudian dilakukan perapihan data untuk dapat dikonversi menjadi bentuk tabulasi untuk keperluan pemodelan *machine learning*, dengan fitur isian sebagai berikut:

No	Fitur	Deskripsi
1	Nama pemenang	Nama perusahaan pemenang
2	Ada Temuan	Ada temuan atau tidak dalam LHA
3	Nilai kontrak	Nilai kontrak yang tercantum di LHA
4	Nilai HPS	Nilai HPS yang tercantum di SPSE
5	Durasi pengumuman s/d penetapan	Lama hari kalender sejak awal pengumuman s.d selesai
6	Rentang lama tahun anggaran pelaksanaan tender	Periode bulan pelaksanaan t
7	% kotrak / HPS	Persentase perbandingan nilai kontrak/HPS (<i>automated</i>)
8	% selisih timpang	Persentase nilai selisih kontrak ideal dengan eksisting (1-% kontrak/HPS) (<i>automated</i>)
9	Skor Potential <i>Fraud</i> analysis dari Opentender	Skor nilai PFA dari situs opentender ICW (www.opentender.net/)

Dari hasil perapihan/pembersihan data, didapatkan 130 data yang valid untuk diteruskan sebagai bahan pemodelan, besaran data masih memenuhi syarat minimal apabila merujuk pada artikel online California Learning Resource Network^[1] untuk keperluan pemecahan masalah klasifikasi sederhana rentang dataset mulai dari 100 sampai dengan 1000

d. Pemodelan

Pada tahapan ini, dilakukan rancang bangun dan pengujian dari setiap pemodelan *machine learning*. Algoritma yang dipilih untuk *machine learning* ini adalah algoritma klasifikasi model k-Nearest Neighbours (KNN) dibuat dengan pemograman python. (source code: <https://github.com/ekacs/ml-prediksi-tender-bermasalah/blob/main/prediksi-tender-KNN2.2.py>)




Gambar1. Alur penyiapan dataset dan kerja *machine learning*

KNN bekerja berdasarkan prinsip bahwa data yang mirip cenderung berada dalam kategori yang sama atau memiliki nilai yang mirip. Pada saat melakukan prediksi, KNN mencari *k-neighbors* (tetangga terdekat) dari data yang ingin diprediksi di antara data pelatihan yang sudah ada. "k" merupakan suatu nilai yang telah ditentukan sebelumnya dan merupakan jumlah tetangga terdekat yang akan digunakan untuk melakukan prediksi. Sehingga, jika $k=3$ (*default*), maka algoritma akan mencari 3 tetangga terdekat dari data yang ingin diprediksi, dan hasil prediksinya akan berdasarkan mayoritas label kategori dari ketiga tetangga tersebut (untuk klasifikasi) atau rata-rata nilai target dari ketiga tetangga tersebut (untuk regresi). Salah satu kelebihan KNN adalah kemudahannya dalam implementasi dan dapat beradaptasi dengan data yang tidak terstruktur dengan baik. Tantangan utamanya, sebagaimana diketahui bahwa kelemahan algoritma KNN memerlukan komputasi yang besar untuk dataset yang besar sehingga apabila pemograman dilakukan menggunakan spesifikasi minimum (RAM <8GB) maka proses pengolahan data oleh *machine learning* akan terasa lambat karena harus melakukan perhitungan jarak untuk setiap titik data yang ada.

e. Evaluasi model


Pengujian setiap algoritma pemodelan mengikuti alur diagram dibawah ini. Data yang telah dikumpulkan sebelumnya dibagi menjadi 70% untuk training set, sebagai bahan latih pemodelan. Sedangkan 30% data yang dikumpulkan sebagai bahan ujicoba untuk mengukur hasil prediksi. Hasil prediksi akan dituangkan dalam skor akurasi model. Hasilnya diketahui untuk saat ini akurasi modelnya adalah 73% atau 0,73



Gambar2. Skema pengukuran akurasi prediksi *machine learning*

f. Purwarupa aplikasi

Rancangan machine learning yang telah dibuat dibangun dalam bentuk aplikasi berbasis website, untuk saat ini dibangun di platform komunitas machine learning streamlit.io



Gambar 3. Alur penggunaan dan pemanfaatan *Machine Learning* berbasis website

Cara kerja penggunaannya sebagai berikut:

- 1) Untuk dapat mengakses aplikasi kunjungi link <https://prediksi-tender-bermasalah-v2.streamlit.app/>

Red flag tender prediction app

Aplikasi ini bertujuan untuk memprediksi apakah tender tersebut berpotensi menjadi temuan

Prediksi temuan dimaksud adalah:

- 1) Keterlambatan pekerjaan
- 2) Realisasi pekerjaan tidak sesuai spektek
- 3) Realisasi pekerjaan tidak sesuai volume
- 4) Realisasi Perusahaan pendukung pekerjaan tidak sesuai penawaran

Prediksi ini bekerja berdasarkan pengolahan data hasil audit, data umum lelang dan skor potensial fraud analisis dari ICW menggunakan algoritma machine learning KNN

Artikel rancangan pembuatan machine learning ini dapat dilihat di [karya tulis ini](#)

Unggah master data penelitian awal (format CSV)



Drag and drop file here

Limit 200MB per file • CSV

Browse files

Gambar 4. Tampilan awal purwarupa aplikasi Ketika pertamakali dijalankan

- 2) Selanjutnya tahap awal diminta mengunggah master data penelitian awal, yaitu dataset yang sudah diolah peneliti agar *machine learning* selanjutnya dapat bekerja, berikut link download databasenya <https://s.id/database-ML> password: korwas2redflag

Unggah master data penelitian awal (format CSV)

 Drag and drop file here
Limit 200MB per file • CSV

Browse files

 TABLE_TENDER1.csv 6.9KB ×

basis data penelitian awal: 130 record

Skor akurasi Model saat ini: 0.7307692307692307

Gambar 5. Tampilan purwarupa aplikasi setelah dimasukkan master data

Setelah data penelitian awal dimasukkan, aplikasi akan menunjukkan skor akurasi model saat ini dan selanjutnya pengguna dapat mengisi isian sesuai form aplikasi dan hasilnya, aplikasi akan mengeluarkan pendapat apakah tender tersebut berpotensi terdapat temuan atau tidak

Prediksi baru

Masukkan teks bebas judul tender, kode tender dan lainnya

Press Ctrl+Enter to apply

Isikan nilai kontrak

Isikan nilai HPS

Isikan lama hari kalender proses lelang mulai awal pengumuman s/d penetapan pemenang akhir

0 - +

Isikan rentang lama tahun anggaran pelaksanaan tender

0 - +

Isikan skor PFA bersumber dari <https://www.opentender.net/tender>

0.00 - +

Mari prediksi apakah terdapat temuan (Y) atau tidak (T)

Gambar 6. Tampilan isian informasi tender yang hendak diprediksi

4. Pembahasan hasil penelitian

Pada tahap ini, penelitian berusaha mengevaluasi efektivitas model Machine Learning (ML) berbasis K-Nearest Neighbors (KNN) dalam memprediksi tender bermasalah sebagai bagian dari audit intern. Pembahasan hasil difokuskan pada akurasi model, tantangan yang ditemukan, serta peluang pengembangan sistem untuk meningkatkan efisiensi deteksi fraud dalam pengadaan barang dan jasa (PBJ).

a. Akurasi Model dan Validasi Data

Hasil uji coba model KNN menunjukkan bahwa sistem memiliki **akurasi sebesar 73%** dalam mengidentifikasi tender bermasalah berdasarkan dataset yang digunakan. Hal ini menunjukkan potensi ML sebagai alat bantu auditor dalam **memprioritaskan objek pemeriksaan** dengan pendekatan berbasis data.

Meskipun hasilnya cukup menjanjikan, akurasi model masih di bawah 80%, yang **menunjukkan perlunya peningkatan kualitas dan kuantitas dataset**. Faktor yang memengaruhi akurasi antara lain:

- 1) **Keterbatasan jumlah dataset**, hanya terdiri dari **130 data valid**, yang masih relatif kecil untuk sistem ML yang kompleks;

- 2) **Kelengkapan variabel** dalam dataset belum mencakup faktor-faktor seperti **informasi sanggahan, profil perusahaan pendukung, dan rekam jejak panitia tender, yang berpotensi meningkatkan prediksi sistem.**
- 3) **Ketidakseimbangan data**, di mana jumlah tender bermasalah lebih sedikit dibandingkan dengan tender yang normal, yang dapat memengaruhi pembelajaran algoritma ML.

b. Efektivitas Purwarupa dalam Audit atas risiko tender

Implementasi purwarupa ML dalam bentuk **aplikasi berbasis website** memberikan kemudahan bagi auditor dalam melakukan prediksi tender bermasalah. Auditor dapat memasukkan informasi tender seperti **nilai kontrak, lama proses tender, dan skor fraud analysis dari ICW**, lalu mendapatkan hasil prediksi secara otomatis.

Keunggulan sistem ini meliputi:

- 1) **Meningkatkan efisiensi kerja auditor**, memungkinkan pemilihan objek audit yang lebih akurat;
- 2) **Mengurangi risiko audit manual**, terutama dalam kasus *false positive* yang dapat membebani sumber daya auditor;
- 3) **Memanfaatkan data dari sumber terpercaya**, seperti **hasil audit internal dan data publik SPSE**, meningkatkan keakuratan analisis fraud.

c. Tantangan dan Peluang Pengembangan

Meskipun purwarupa ini telah menunjukkan potensi dalam meningkatkan audit tender, terdapat beberapa tantangan yang perlu diatasi:

- 1) **Mekanisme pengumpulan dataset untuk machine learning dilakukan secara manual** dan hanya bersumber informasi hasil audit Inspektorat Jenderal yang tuntas ditindaklanjuti oleh Auditi, sehingga **penting untuk mengalokasikan waktu yang cukup** apabila ingin menargetkan jumlah dataset yang lebih banyak dan apabila dimungkinkan memasukkan informasi hasil audit yang masih proses tindaklanjutnya
- 2) **Pengumpulan dataset yang lebih besar dan variatif** untuk meningkatkan akurasi, yaitu dengan data perlu diperbanyak dan **perlu ditambahkan variabel tambahan antara lain** informasi sanggahan, keberadaan perusahaan pendukung, pengaduan yang mungkin ada, profil panitia pemilihan tender, profil peserta tender dan lainnya yang dipandang memberikan pengaruh pelaksanaan tender
- 3) **Integrasi dengan metode audit tradisional**, agar ML tidak menggantikan auditor sepenuhnya, **tetapi mengoptimalkan peran manusia dalam audit;**
- 4) **Peningkatan algoritma dan fitur**, seperti eksplorasi model **Generative AI** atau **ensemble learning** untuk meningkatkan akurasi prediksi;
- 5) **Aspek regulasi dan kepatuhan**, karena penggunaan AI dalam audit harus sesuai dengan kebijakan hukum dan etika yang berlaku di Indonesia.

5. Penutup

a. Simpulan

Secara keseluruhan, penelitian ini menunjukkan bahwa **Machine Learning berbasis KNN memiliki potensi sebagai alat bantu dalam audit atas risiko tender**. Purwarupa yang dikembangkan berhasil memberikan hasil prediksi dengan tingkat akurasi yang cukup baik, meskipun masih terdapat tantangan yang perlu diselesaikan sebelum implementasi secara lebih luas.

5.2 Saran

Peningkatan dataset, eksplorasi variabel tambahan, dan integrasi teknologi AI yang lebih canggih kedepannya diharapkan dapat mengoptimalkan sistem ini sebagai bagian dari strategi Audit atas risiko tender dan bentuk konkrit early warning system oleh Inspektorat Jenderal selaku Aparat Pengawasan Intern

6. Daftar Pustaka

- Christensen, B. E., Emmett, S. A., Eulerich, M., Wood, D. A., Allison, B., Hofmann, H., & Hribesek, L. (2025). Using Artificial Intelligence for Fraud Risk Assessment: Evidence from Novice and Experienced Auditors.
- How much data is needed for machine learning? By CLRN 24th November 2024
(<https://www.clrn.org/how-much-data-is-needed-for-machine-learning>)
- Gölyeri, M., Çelik, S., Bozyiğit, F., & Kılınc, D. (2023). *Fraud* detection on e-commerce transactions using machine learning techniques. In *Artificial Intelligence Theory and Applications* (Vol. 3, Issue 1).
- Al-Milli, N., & Al-Khatib, T. (2021). "KNN-Based Fraud Detection in E-commerce: A Case Study." *Journal of E-commerce Research*, 15(2), 89-102.
- Setyawan, Eka C.(2021). The Effect Of Financial Performance On Corruption Indications With Internal Control System As Moderation At The Ministry Of Transportations.
- Patel, R., et al. (2020). "Improving Fraud Detection with Ensemble Learning and KNN." *Proceedings of the International Conference on Data Science*, 123-130.
- Kumar, A., & Vishwakarma, S. (2019). "Enhancing Fraud Detection Using KNN and Data Preprocessing Techniques." *International Journal of Advanced Computer Science and Applications*, 10(7), 234-240.
- Zhang, Y., et al. (2018). "Application of KNN Algorithm in Credit Card Fraud Detection." *Journal of Financial Technology*, 12(3), 45-56.
- Shifeng Wang. Procurement fraud methods and auditing strategies. [Chinese Market][Volume 44], 2015
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer Science & Business Media.
- Peraturan Pemerintah Republik Indonesia Nomor 60 Tahun 2008 Tentang SPIP.
- Venter, A. C. (2007). A procurement fraud risk management model. In *Meditari Accountancy Research* (Vol. 15, Issue 2).
- Hugo W.M.J., Badenhorst-Weiss J.A., and Van Rooyen D.C. Procurement and supply management. 5th edition. Pretoria: Van Schaik, 2006
- Raymond C. McCann. Procurement fraud investigative techniques: The need for congressional expansion of the inspector general subpoena power to include the power to compel testimony. [Public Contract Law Journal][Volume 16, No. 2], 1986